



الجمهورية العربية السورية
وزارة التعليم العالي
جامعة اللاذقية الحرّة – كلية الهندسة المعلوماتية
قسم الذكاء الصناعي

مساعد ذكي للتغذية وتحليل الوجبات Smart nutrition assistant and meal analysis

مشروع تخرج

إعداد الطالب
عمر أحمد مصطاوي

إشراف
د. محمد ماشي

2026/2025

جدول المحتويات

5	جدول المصطلحات
6	الفصل الأول: مقدمة المشروع
7	الفصل الثاني: الدراسات السابقة وتحليل الأبحاث المرجعية
7	الدراسة الأولى
7	أهم التقنيات المستخدمة
8	النتائج المهمة في الدراسة
8	الاستفادة من الدراسة في مشروعنا
8	القيود التي لاحظتها الدراسة
9	الدراسة الثانية
10	الدراسة الثالثة
11	الفكرة الأساسية للنظام
11	أنواع الشروحات المستخدمة
12	آلية التوصية الغذائية
13	نتائج الدراسة
14	العلاقة مع النظام الحالي
15	الفصل الثالث: تحليل متطلبات النظام
16	الفصل الرابع: معمارية النظام (System Architecture)
17	1) استقبال رسالة المستخدم (User Input Processing)
17	2) اكتشاف النية (Intent Detection)
17	3) اكتشاف التحيزات (Greeding Detection)
18	4) استخراج الكيانات (Entity Extraction)
18	5) الذاكرة والسياق (Memory Management)
19	6) أسئلة التوضيح (Clarification Questions)
19	7) معالجة النوايا (Intent Handlers)
19	8) محرك التوصية (Recommendation Engine)
20	9) توليد الاستجابة (Response Generator)
21	مخطط تدفق النظام (Flowchart)
22	الفصل الخامس: مراحل تطوير النظام
22	المرحلة الأولى: استخدام Deep Learning لبناء Chatbot غذائي
22	التقنيات والمكتبات المستخدمة
24	معالجة البيانات
24	تقسيم البيانات
24	تحميل النموذج
25	التعديلات على الـ Tokenizer
25	نوع التدريب
25	الهدف من هذه المرحلة
26	النموذج الأول

26	نتائج التدريب
26	المشاكل التي ظهرت
26	أمثلة على النتائج الخاطئة
27	المرحلة الثانية: توسيع البيانات والتدريب على Kaggle
27	نتائج التدريب
28	المشاكل التي استمرت
28	أمثلة على المشاكل
28	تحليل أسباب فشل استخدام Deep Learning
29	الانتقال إلى النهج الحالي
30	التقنيات المستخدمة
30	نوع البيانات المستخدمة
31	تنظيف البيانات
31	تحليل البيانات (EDA)
31	بناء وتجهيز البيانات النصية (Text Preparation)
32	بناء ملف توصيف الوجبات (Meal Profile Construction)
33	تطبيع القيم الغذائية (Feature Normalization)
35	نظام فهم النية (Intent Classification)
35	آلية التدريب
36	الدقة Accuracy
36	Semantic Matching
37	Recommendation Engine
38	Memory & Session State
38	Greeting Detection
39	مميزات النهج الحالي
39	مقارنة بين النهجين
39	الاستنتاج النهائي
40	تصميم واجهات المستخدم (User Interface Design)
41	مكونات الواجهة الرئيسية
44	الفصل الأخير: الأعمال المستقبلية
45	المراجع (References)

فهرس الصور

31	صورة 1 – توزع الداتا
32	صورة 2 - الداتا
36	صورة 3- confusion matrix
42	صورة 4 – واجهة - 1
42	صورة 5 واجهة - 2
43	صورة 6 واجهة - 3

فهرس الجداول

5	جدول 1 - جدول المصطلحات
13	جدول 2 - أفكار مستفادة من الدراسة المرجعية
23	جدول 3 - مصادر الداتا بيز المستخدمة
39	جدول 4 - مقارنة بين المظام الهجين وDL

الاختصار	المعنى
AI	Artificial Intelligence
ML	Machine Learning
NLP	Natural Language Processing
XAI	Explainable Artificial Intelligence
TF-IDF	Term Frequency – Inverse Document Frequency
VAE	Variational Autoencoder
GRU	Gated Recurrent Unit
EDA	Exploratory Data Analysis
API	Application Programming Interface
BMR	Basal Metabolic Rate
BMI	Body Mass Index
AMR	Active Metabolic Rate
UI	User Interface
CSV	Comma-Separated Values

جدول 1 - جدول المصطلحات

الفصل الأول: مقدمة المشروع

نبذة عن المشروع

يهدف هذا المشروع إلى تطوير مساعد ذكي يعتمد على تقنيات الذكاء الاصطناعي ومعالجة اللغة الطبيعية (NLP) لمساعدة المستخدمين في تحليل الوجبات الغذائية، اقتراح وجبات مناسبة، مقارنة الوجبات، والإجابة على الأسئلة المتعلقة بالتغذية والأهداف الصحية المختلفة.

يعتمد النظام على نماذج تعلم آلي وتقنيات فهم النصوص لاستخراج نية المستخدم (Intent Detection) وفهم الهدف الغذائي ونوع الوجبة والمعلومات المطلوبة من الرسائل النصية المدخلة.

أهداف المشروع

- بناء Chatbot ذكي قادر على فهم اللغة الطبيعية.
- تصنيف نية المستخدم بدقة.
- تحليل الوجبات الغذائية.
- اقتراح وجبات مناسبة حسب الهدف الغذائي.
- مقارنة الوجبات وإظهار الفروقات الغذائية.
- توفير تجربة تفاعلية سهلة الاستخدام.
- استخدام تقنيات Machine Learning و NLP ضمن مشروع عملي متكامل.

المشكلة التي يحلها المشروع

يعاني الكثير من المستخدمين من صعوبة:

- اختيار وجبات مناسبة لأهدافهم الصحية.
- فهم القيم الغذائية للوجبات.
- الحصول على توصيات غذائية سريعة ومخصصة.
- مقارنة الوجبات بطريقة سهلة.

يقدم المشروع حلاً ذكياً يعتمد على المحادثة الطبيعية لتسهيل الوصول إلى المعلومات الغذائية.

الفصل الثاني: الدراسات السابقة وتحليل الأبحاث المرجعية

الدراسة الأولى

AI nutrition recommendation using a deep generative model and ChatGPT

تركز الدراسة على تطوير نظام توصية غذائية ذكي يعتمد على الدمج بين:

- Deep Generative Models
 - ChatGPT
 - Personalized Nutrition Planning
- بهدف إنشاء خطط غذائية أسبوعية مخصصة تتوافق مع:
- الحالة الصحية للمستخدم
 - الهدف الغذائي
 - المعايير الصحية العالمية مثل :
 - World Health Organization
 - European Food Safety Authority
- أهم التقنيات المستخدمة

Variational Autoencoder (VAE) (1

استخدمت الدراسة:

$$L=LMC+LKLD+LEI+Lmacro$$

لتحويل بيانات المستخدم إلى تمثيل latent space يسمح بتوليد خطط غذائية متنوعة.

GRU Decoder (2

تم استخدام:

- GRU Layers
- Sequence Generation

لتوليد تسلسل وجبات يومية.

(3 استخدام ChatGPT

تم استخدام:

- OpenAI
- ChatGPT

لتوسيع قاعدة بيانات الوجبات وتوليد بدائل غذائية جديدة.

النتائج المهمة في الدراسة

حققت الدراسة:

• دقة ماكروز $\approx 87\%$

• فرق سعرات $\approx 0\%$

• زمن توليد ≈ 500 ms

كما تفوقت على استخدام ChatGPT وحده.

الاستفادة من الدراسة في مشروعنا

ساعدت هذه الدراسة في:

• فهم استخدام النماذج التوليدية في التغذية .

• تحليل مشاكل الـ Generative AI .

• معرفة أهمية :

◦ Personalization

◦ Recommendation Systems

◦ Constraint-based Nutrition

كما دعمت فكرة استخدام:

• Semantic Understanding

• Meal Recommendation Logic

داخل المشروع الحالي.

القيود التي لاحظتها الدراسة

أكدت الدراسة على وجود مشاكل مثل:

• Hallucination

• ضعف الدقة أحياناً

• الحاجة للتحقق البشري

• صعوبة ضمان التوصيات الطبية

وهي مشاكل مشابهة لما ظهر أثناء تجاربنا باستخدام Deep Learning.

ChatGPT as a Virtual Dietitian: Exploring Its Potential as a Tool for Improving Nutrition Knowledge

أهم ما توصلت إليه الدراسة

أوضحت الدراسة أن ChatGPT قادر على:

- تقديم معلومات غذائية عامة .
- حساب بعض المؤشرات الغذائية .
- تحسين التثقيف الغذائي .
- لكن الدراسة أكدت أيضاً على مشاكل مهمة:
- ضعف التخصيص .
- احتمالية الأخطاء .
- غياب الفهم الإنساني .
- ضعف الاعتمادية الطبية.

علاقتها بالمشروع الحالي

دعمت هذه الدراسة قرار عدم الاعتماد الكامل على:

Generative AI

ChatGPT-only Systems

والاتجاه نحو:

Hybrid Recommendation Systems

Rule-Based Validation

Structured Meal Recommendation

Towards interactive explanation based nutrition virtual coaching systems

تتناقش هذه الدراسة تطوير نظام توصية غذائية تفاعلي قابل للتفسير (Interactive Explainable Nutrition Recommendation System)، يهدف إلى تحسين تجربة المستخدم من خلال دمج:

- التوصية الغذائية .
- التفاعل الحواري .
- الشروحات التفسيرية .
- التغذية الراجعة (Feedback).
- تركز الدراسة على زيادة:

- الشفافية (Transparency).
- ثقة المستخدم .
- التفاعل الاجتماعي مع النظام .
- فعالية التوصيات الغذائية الشخصية.

أهمية الدراسة

تكتسب هذه الدراسة أهمية كبيرة لأن أنظمة التوصية الغذائية التقليدية غالباً:

- تقدم اقتراحات آلية غير مفسرة .
- لا تراعي تفضيلات المستخدم بشكل ديناميكي .
- تقلل من ثقة المستخدم بالتوصيات .
- بينما يقترح البحث نظاماً يسمح للمستخدم:
- تعديل التوصيات .
- نقد الوصفات .
- طلب تفسير للقرارات .
- التفاعل المستمر مع النظام .
- وهو اتجاه حديث ضمن مجال:

• Explainable AI (XAI)

• Interactive Recommendation Systems

الفكرة الأساسية للنظام

يعتمد النظام على حلقة تفاعلية مستمرة بين:

- المستخدم .
- نظام التوصية الغذائية .
- حيث يقوم المستخدم بإدخال:
- التفضيلات الغذائية .
- الحساسيات .
- القيود الصحية .
- نوع المطبخ المفضل .
- ثم يقوم النظام:

- باقتراح وصفة .
- شرح سبب التوصية .
- استقبال ملاحظات المستخدم .
- تعديل التوصية أو الشرح بناءً على التغذية الراجعة.

أنواع الشروحات المستخدمة

اعتمدت الدراسة عدة أنواع من التفسيرات، منها:

User-Centered Explanation (1

تركز على أهداف المستخدم مثل:

- خسارة الوزن.
- زيادة الوزن.
- تحسين الصحة.

Content-Based Explanation (2

تعتمد على خصائص الطعام نفسه مثل:

- البروتين.
- الدهون.
- السعرات.

Contrastive Explanation (3)

تشرح سبب اختيار وصفة معينة بدلاً من وصفات أخرى

Contextual Explanation (4)

تأخذ بعين الاعتبار:

- الوقت.
- الموسم.
- الحالة الصحية.
- تفضيلات المستخدم.

آلية التوصية الغذائية

اعتمد النظام على:

(1) تصفية الوصفات (Filtering)

يتم حذف الوصفات غير المناسبة اعتماداً على:

- الحساسية الغذائية .
- القيود الدينية .
- التفضيلات الشخصية.

(2) المنفعة (Utility Estimation)

تم تقييم الوصفات اعتماداً على:

- AMR Score
 - Nutrition Score
 - User Satisfaction Score
- ثم حساب قيمة منفعة نهائية لاختيار أفضل وصفة.

Explainable Recommendation (3)

استخدمت الدراسة:

- Decision Trees
- لتوليد تفسيرات واضحة لسبب اقتراح وصفة معينة.

وتم استخدام:

- User-based Explanation
- Item-based Explanation

لتحسين فهم المستخدم للنظام.

نتائج الدراسة

أظهرت النتائج أن النظام التفاعلي:

- حقق قبولاً أعلى لدى المستخدمين .
- زاد من رضا المستخدم .
- حسن التفاعل الاجتماعي .
- قدم معلومات أكثر وضوحاً مقارنة بالنظام التقليدي .

كما فضّل:

- 45 من أصل 54 مستخدم النظام التفاعلي.

الاستفادة من الدراسة في مشروعنا

استفاد المشروع الحالي من عدة أفكار مطروحة في هذه الدراسة، أهمها:

تطبيقها في المشروع	الفكرة في الدراسة
المحادثة التفاعلية مع المستخدم	Interactive Recommendation
شرح سبب اقتراح الوجبة	Explainable AI
تحليل meal type و goal	User Preferences
أسئلة التوضيح	Clarification Questions
اقتراح وجبات حسب الهدف	Personalized Nutrition
مراعاة نوع الوجبة والهدف الغذائي	Context-aware Recommendation

جدول 2 - أفكار مستفادة من الدراسة المرجعية

العلاقة مع النظام الحالي

يتشابه النظام الحالي مع الدراسة في عدة نقاط، منها:

- الاعتماد على التفاعل الحواري .
 - تقديم توصيات غذائية شخصية .
 - تفسير الاقتراحات الغذائية .
- لكن المشروع الحالي يختلف في:
- استخدام Semantic Matching .
 - استخدام Intent Classification .
 - الاعتماد على Hybrid ML Architecture بدلاً من Decision Trees فقط .
 - دعم العربية والإنجليزية .
 - دمج Recommendation Engine مع Chatbot تفاعلي.
-

الفصل الثالث: تحليل متطلبات النظام

المتطلبات الوظيفية (Functional Requirements)

النظام يجب أن يكون قادراً على:


- استقبال سؤال المستخدم
- تحديد النية (Intent)
- اقتراح وجبات
- إنشاء خطة غذائية
- مقارنة وجبتين
- تحليل وجبة
- اقتراح بدائل
- حفظ سياق المحادثة

المتطلبات غير الوظيفية (Non-Functional Requirements)

مثلاً:

- سرعة استجابة أقل من 3 ثوان
 - واجهة سهلة الاستخدام
 - دعم العربية والإنجليزية
 - قابلية التوسع
 - قابلية الصيانة
 - استقرار النظام
-

الفصل الرابع: معمارية النظام (System Architecture)



(1) استقبال رسالة المستخدم (User Input Processing)

يقوم النظام باستقبال الرسالة النصية المدخلة من المستخدم
الهدف من هذه المرحلة:

- إزالة الفراغات الزائدة .
- التحقق من عدم كون الرسالة فارغة .
- تجهيز النص للمعالجة.

(2) اكتشاف النية (Intent Detection)

يستخدم النظام نهجًا هجينًا لتحديد نية المستخدم بدقة أعلى من الاعتماد على نموذج واحد فقط.
يتكون النظام من:

(أ) نموذج ML

تم استخدام:

- Logistic Regression
- TF-IDF Features

لتوقع النية:

```
intent=intent_model.predict([user_text])[0]
```

(ب) الفهم الدلالي Semantic Understanding

تم استخدام:

- SentenceTransformer
- paraphrase-multilingual-MiniLM-L12-v2

(3) اكتشاف التحيات (Greeting Detection)

قبل متابعة تنفيذ الطلب، يتحقق النظام إذا كانت الرسالة تحتوي على تحية:

النظام يدعم:

العربية

- مرحبا
- أهلاً

• السلام عليكم

الإنجليزية

• hello

• hi

• good morning

الهدف:

• تحسين تجربة المستخدم .

• جعل المحادثة أكثر طبيعية .

(4) استخراج الكيانات (Entity Extraction)

بعد تحديد النية يقوم النظام باستخراج المعلومات المهمة من الرسالة:

goal=extract_goal(user_text)

meal_type=extract_meal_type(user_text)

workout=extract_workout_intent(user_text)

meal_name=find_meal_name_in_text(user_text)

(5) الذاكرة والسياق (Memory Management)

تم بناء نظام ذاكرة يسمح باستمرار المحادثة دون إعادة إدخال جميع المعلومات في كل مرة.

النظام يخزن:

• آخر هدف غذائي

• آخر نوع وجبة

• آخر وجبات مقارنة

• النية المعلقة

• خيارات التوضيح

(6) أسئلة التوضيح (Clarification Questions)

عندما تكون البيانات ناقصة يقوم النظام بطلب معلومات إضافية.

مثال:

إذا كتب المستخدم:

Recommend meal

يقوم النظام بالتحقق:

if not goal or not meal_type:

ثم:

ask_clarification()

مثال الرد:

What is your goal?

- Weight Loss
- Weight Gain
- Maintenance

ميزة هذه الخطوة:

• تقليل الأخطاء .

• تحسين دقة التوصيات.

(7) معالجة النوايا (Intent Handlers)

بعد تحديد النية، يقوم النظام بتوجيه الطلب إلى الوحدة المناسبة.

(8) محرك التوصية (Recommendation Engine)

يعتمد النظام على عدة عوامل:

التشابه النصي

باستخدام:

cosine_similarity

الهدف الغذائي

مثل:

Weight Loss .

Weight Gain .

Maintenance .

نوع الوجبة

مثل:

Breakfast .

Lunch .

Dinner .

Snack .

القيم الغذائية

Calories .

Protein .

Carbs .

Fat .

(9) توليد الاستجابة (Response Generator)

بعد الحصول على النتائج يتم بناء الرد:

```
response={  
  "intent":intent,  
  "results":top  
}
```

الرد يتضمن:

. اسم الوجبة

. السعرات

. البروتين

. الدهون

. الكربوهيدرات

. تفسير سبب الاقتراح

Start



Receive User Input



Greeting?

├ Yes → Respond Greeting



└ No



Predict Intent



Intent Found?

├ No → Ask clarification



└ Yes



Extract goal



Find meals



Generate response



Store memory



End

الفصل الخامس: مراحل تطوير النظام

المرحلة الأولى: استخدام Deep Learning لبناء Chatbot غذائي

في بداية المشروع تم الاعتماد على نماذج Deep Learning لبناء مساعد غذائي ذكي قادر على فهم طلبات المستخدم وتوليد ردود غذائية مناسبة بشكل تلقائي.

تم استخدام النموذج google/flan-t5-base وهو نموذج لغوي توليدي مبني على معمارية Transformer من أجل تنفيذ Fine-Tuning على بيانات المحادثات الغذائية، ويستخدم أسلوب Sequence-to-Sequence (Seq2Seq) أي تحويل نص إلى الإدخال إلى نص مخرجات.

الهدف من النموذج

- بناء Chatbot غذائي قادر على:
 - فهم سؤال المستخدم.
 - توليد رد غذائي تلقائي.
 - إنشاء خطط غذائية.
 - اقتراح وجبات.
 - تحليل الوجبات.
 - محاكاة أسلوب المحادثة البشرية.
- بدلاً من الاعتماد على قواعد ثابتة أو استرجاع مباشر للبيانات.

التقنيات والمكتبات المستخدمة

المكتبات الأساسية

تم استخدام:

- pandas
- torch
- numpy
- datasets
- transformers
- scikit-learn
- nltk
- evaluate

نوع البيانات المستخدمة

تم تدريب النموذج على ملف:

- conversations.csv

ويحتوي على:

- input_text
- target_text

حيث:

- input_text يمثل سؤال المستخدم
- target_text يمثل الرد المتوقع من النظام

تم استخدام أسلوب التعلم الموجه (Supervised Learning) حيث يتم تدريب النموذج على أزواج من بيانات الإدخال والمخرجات.

تم تدريب النموذج باستخدام Dataset غذائي يحتوي على حوالي 2734 سجل (Rows) ، وكانت الفكرة الأساسية تعتمد على جعل النموذج يتعلم الأنماط الغذائية والردود المناسبة اعتماداً على البيانات التدريبية. تم بناء محادثات لتشكيل داتا conversations.csv بالاعتماد على عدة مصادر منفصلة لتحويلها من بيانات مجدولة إلى محادثات. الداتا:

- recipes.csv من Food.com - Recipes and Reviews موجودة على kaggle
- detailed_meals_macros_CLEANED.csv من Healthy Meal Plan Dataset موجودة على Kaggle
- arab_meals_120.csv تم توليدها باستخدام أدوات ذكاء اصطناعي لتغطية حالات غذائية إضافية.

الاستخدام	عدد السجلات	المصدر	Dataset
إنشاء المحادثات	522516 سجل	Kaggle	recipes.csv
بيانات غذائية	1699 سجل	Kaggle	detailed_meals_macros_CLEANED.csv
توصيات عربية	360 سجل	AI Generated	arab_meals_120.csv

جدول 3 - مصادر الداتابيز المستخدمة

مجموع الداتا المدربة في النموذج الأول 2700 سجل من المحادثات وفي النموذج الثاني 24,000

معالجة البيانات

تم تنفيذ عدة خطوات Preprocessing قبل التدريب:
تنظيف النصوص
تم:

- حذف الفراغات الزائدة.
- توحيد تنسيق النص.
- إزالة الأسطر غير الضرورية.
- تنظيف القيم الفارغة.

وذلك لتحسين جودة البيانات المدخلة للنموذج.

تقسيم البيانات

تم تقسيم البيانات باستخدام: `train_test_split` بحيث:

- 90% Training
- 10% Evaluation

مع استخدام:

- `random_state = 42`

لضمان ثبات النتائج.

تحميل النموذج

تم تحميل النموذج الأساسي:

- `google/flan-t5-base`

باستخدام:

- `AutoTokenizer`

- `AutoModelForSeq2SeqLM`

ثم تم تنفيذ Fine-Tuning عليه باستخدام بيانات المشروع.

التعديلات على الـTokenizer

تم إضافة Special Tokens للمحادثة:

-
-
-

وذلك لمحاكاة بنية المحادثات الحديثة وتحسين فهم الأدوار داخل الحوار.

Tokenization

تم استخدام:

• tokenizer

مع:

• truncation=True

• max_length=512

لتقليل استهلاك الذاكرة ومنع تجاوز الحد الأقصى لطول النص.

نوع التدريب

تم استخدام:

• Seq2SeqTrainer

وهو Trainer مخصص لتدريب النماذج التوليدية.

كما تم استخدام:

• DataCollatorForSeq2Seq

لتجهيز البيانات أثناء التدريب.

الهدف من هذه المرحلة

الهدف الأساسي كان:

- جعل النموذج قادراً على توليد ردود طبيعية ومرنة.
- إنشاء محادثة شبيهة بالمساعدات الذكية الحديثة.
- تقليل الحاجة إلى القواعد البرمجية.

النموذج الأول

تم تنفيذ أول نسخة من المشروع تحت اسم: nutrition_chatbot_final واعتمدت هذه النسخة على تدريب نموذج توليدي لإنتاج الردود الغذائية مباشرة.

نتائج التدريب

بلغت قيمة الـ Loss أثناء التدريب:

$$\text{Loss}=7.3217$$

ورغم نجاح النموذج تقنياً في توليد ردود نصية، إلا أن النتائج العملية أظهرت عدداً من المشاكل المهمة.

المشاكل التي ظهرت

من خلال الاختبار العملي لوحظ أن النموذج:

1. يولد إجابات غير مرتبطة بالسؤال أحياناً.
2. يخلط بين أهداف المستخدم الغذائية مثل:
 - زيادة الوزن
 - خسارة الوزن
 - المحافظة على الوزن
3. يقدم وجبات غير مناسبة للهدف المطلوب.
4. يكرر نفس الأنماط اللغوية بشكل كبير.
5. لا يحافظ على منطق غذائي ثابت داخل الرد.
6. يعاني من الهلوسة (Hallucination) وإنتاج معلومات عشوائية.
7. التناقض الغذائي

أحياناً:

- يقترح وجبات عالية السعرات لخسارة الوزن.
- يخلط بين pre-workout و post-workout .
- يولد خطط غير منطقية.

أمثلة على النتائج الخاطئة

المثال الأول

السؤال:

Create a 7-day meal plan for someone with Weight Gain

النتيجة:

Yes — Baked egg with whole wheat bread is a strong option for endurance...

المشكلة هنا أن النموذج:

- لم ينشئ خطة أسبوعية.
- تجاهل طلب زيادة الوزن.
- أعطى اقتراح وجبة منفردة فقط.

المثال الثاني

السؤال:

Recommend a meal to loss weight

النتيجة:

Grilled Chicken with Meat and Vegetables...

المشكلة:

- الوجبة المقترحة لا تتوافق بشكل دقيق مع هدف خسارة الوزن.
- التفسير الغذائي غير منطقي بالكامل.

المرحلة الثانية: توسيع البيانات والتدريب على Kaggle

بعد ضعف نتائج النموذج الأول، تم تطوير نسخة ثانية من المشروع تحت اسم: nutrition_chatbot_v2 وتم استخدام منصة Kaggle لتدريب النموذج باستخدام بيانات أكبر حجماً.

بيانات التدريب

تمت زيادة حجم البيانات إلى حوالي:

24000+ rows

في هذا النموذج استخدمنا كامل المحادثات.

كما تم رفع النموذج على منصة: Kaggle

nutrition-chatbot-24000-rows model

نتائج التدريب

بلغت قيمة الـ Loss:

Loss=10.2286

ورغم زيادة حجم البيانات بشكل كبير، بقيت هناك مشاكل واضحة في جودة المخرجات.

المشاكل التي استمرت

- إنشاء خطط غذائية غير مترابطة.
- تكرار أسماء وجبات بشكل عشوائي.
- ظهور كلمات غير مفهومة أو جمل غير مكتملة.
- ضعف فهم النية. (Intent Understanding)
- عدم الثبات في بنية الردود.
- توليد وجبات غير منطقية غذائياً.

أمثلة على المشاكل

المثال الأول

السؤال:

Create a 7-day meal plan for someone with Weight Gain

النتيجة تضمنت:

Breakfast waxie with protein powder

وهي عبارة غير منطقية ناتجة عن أخطاء التوليد.

المثال الثاني

السؤال:

Recommend a meal to loss weight

النتيجة:

Chicken and EggSoup with Rice

ثم قام النموذج بإعطاء تفسير غذائي متناقض وغير دقيق.

تحليل أسباب فشل استخدام Deep Learning

بعد تحليل النتائج تبين أن استخدام النماذج التوليدية في هذا النوع من المشاريع يواجه عدة تحديات، أهمها:

1. الحاجة إلى Dataset ضخمة وعالية الجودة.
2. صعوبة ضبط الردود الغذائية منطقياً.
3. احتمالية توليد معلومات غذائية خاطئة.
4. ضعف القدرة على التحكم الكامل بالمخرجات.
5. الحاجة إلى موارد تدريب كبيرة.
6. مشكلة Hallucination في النماذج التوليدية.

كما أن المجال الغذائي يحتاج إلى:

- دقة عالية.
- منطق ثابت.
- نتائج قابلة للتحكم.
- توصيات موثوقة.

الانتقال إلى النهج الحالي

بناءً على المشاكل السابقة، تم الانتقال إلى تصميم نظام هجين يعتمد على:

- Intent Classification
- Semantic Matching
- Rule-Based Logic
- Retrieval-Based Responses
- Meal Recommendation System

بدلاً من الاعتماد الكامل على توليد النصوص باستخدام Deep Learning.

وقد ساعد هذا النهج على:

- تحسين دقة فهم طلب المستخدم.
- تقليل الأخطاء العشوائية.
- تقديم توصيات غذائية أكثر منطقية.
- زيادة إمكانية التحكم بالردود.
- تحسين تجربة المستخدم بشكل واضح.

أهداف النظام

النظام النهائي يدعم:

- فهم نية المستخدم.
- اقتراح وجبات مناسبة.
- تحليل القيم الغذائية.
- إنشاء خطط غذائية.
- مقارنة الوجبات.
- اقتراح بدائل.

- فهم نوع الوجبة.
 - دعم أهداف:
 - Weight Loss
 - Weight Gain
 - Maintenance
-

التقنيات المستخدمة

مكتبات Machine Learning

تم استخدام:

- scikit-learn
- sentence-transformers
- LogisticRegression
- TfidfVectorizer
- cosine_similarity
- TruncatedSVD
- MultiOutputRegressor

نوع البيانات المستخدمة

تم استخدام ملف:

• arab_meals_120.csv

ويحتوي على معلومات غذائية مثل:

- اسم الوجبة
- المكونات
- الهدف الغذائي
- نوع الوجبة
- السعرات الحرارية
- البروتين
- الكربوهيدرات

• الدهون

تنظيف البيانات

تم تنفيذ:


- إزالة التكرار.
- تحويل القيم الرقمية.
- توحيد النصوص.
- تنظيف القيم الفارغة.
- توحيد الحروف والمسافات.

تحليل البيانات (EDA)

تم إجراء تحليل مبدئي للبيانات يشمل:

- توزيع الأهداف الغذائية.
- توزيع أنواع الوجبات.
- حساب عدد العينات.
- رسم مخططات بيانية.

وذلك لفهم البيانات قبل التدريب.



صورة 1 – توزيع الداتا

بناء وتجهيز البيانات النصية (Text Preparation)

قبل تدريب نماذج فهم النية والتوصية الغذائية، تم تنفيذ مرحلة تجهيز ومعالجة للبيانات بهدف توحيد شكل النصوص وتقليل الاختلافات اللغوية التي قد تؤثر على أداء النموذج.

تم إنشاء دالة **Normalize Text** بهدف:

- تحويل جميع النصوص إلى أحرف صغيرة (Lowercase).
 - إزالة الفراغات الزائدة .
 - تحويل القوائم إلى نص موحد .
 - معالجة القيم الفارغة .
 - توحيد تنسيق البيانات النصية .
- تم تطبيق المعالجة على الحقول الأساسية في قاعدة البيانات:
- الهدف الغذائي (Goal)
 - نوع الوجبة (Meal Type)
 - اسم الوجبة (Name)
 - مكونات الوجبة (Ingredients)
- مما أدى إلى تقليل التكرار وتحسين عملية المطابقة النصية.

بناء ملف توصيف الوجبات (Meal Profile Construction)

تم إنشاء تمثيل نصي موحد لكل وجبة تحت اسم:

Meal Profile

بحيث يجمع أهم المعلومات الخاصة بالوجبة ضمن نص واحد يتضمن:

- اسم الوجبة
- الهدف الغذائي
- نوع الوجبة
- المكونات

	meal_profile	Calories	ProteinContent	CarbohydrateContent	FatContent
0	name: Foul Medames with Olive Oil and Whole Wheat Bread goal: Muscle Gain meal type: Breakfast ingredients: fava beans, olive oil, lemon, garlic, whole wheat bread	430	18	48	16
1	name: Greek Yogurt with Dates and Walnuts goal: Fat Loss meal type: Breakfast ingredients: greek yogurt, dates, walnuts	320	20	28	12
2	name: Shakshuka with Whole Wheat Bread goal: Maintenance meal type: Breakfast ingredients: eggs, tomatoes, peppers, onions, olive oil, whole wheat bread	410	22	30	18
3	name: Labneh with Za'atar and Olive Oil goal: Muscle Gain meal type: Breakfast ingredients: labneh, zaatar, olive oil, bread	390	17	24	22
4	name: Oatmeal with Tahini and Banana goal: Endurance meal type: Breakfast ingredients: oats, tahini, banana, milk	450	16	60	14

صورة 2 - الداتا

تطبيع القيم الغذائية (Feature Normalization)

بسبب اختلاف نطاق القيم الغذائية مثل:

- السرعات الحرارية
- البروتين
- الدهون
- الكربوهيدرات

تم استخدام تقنية Min-Max Normalization لتحويل جميع القيم إلى المجال:

$$0 \leq x \leq 1$$

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

وذلك لتحقيق:

- منع سيطرة خاصية معينة على عملية الترتيب .
- تحسين عدالة المقارنة بين الوجبات .
- تسهيل حساب درجات الجودة الغذائية لاحقًا.

بناء بيانات تدريب النوايا (Synthetic Intent Dataset Generation)

بسبب عدم توفر Dataset جاهزة تحتوي على رسائل مستخدم مصنفة لنظام تغذية ذكي، تم إنشاء بيانات تدريب صناعية. (Synthetic Dataset). اعتمدت العملية على إنشاء قوالب نصية متعددة لكل نية. أمثلة:

Recommend Meal

- Recommend a meal for weight loss
- Give me a healthy meal
- اعطني وجبة مناسبة للتنشيف

Analyze Meal

- Analyze this meal

• Show me nutrition facts

• احسب السعرات والماكروز

Compare Meals

• Compare two meals

• قارن بين وجبتين

استخدام المرادفات (Synonym Expansion)

لزيادة قدرة النموذج على فهم تنوع اللغة، تم إنشاء مجموعات مرادفات للأهداف الغذائية وأنواع الوجبات. مثال للأهداف:

Muscle Gain

• Build muscle

• Bulking

• زيادة العضلات

• تضخيم

مثال لأنواع الوجبات:

Breakfast

• Morning meal

• First meal

• فطور

• إفطار

ساعد ذلك على:

• دعم اللغتين العربية والإنجليزية .

• فهم صيغ مختلفة لنفس الطلب .

• تحسين التعميم. (Generalization)

موازنة بيانات النوايا (Intent Balancing)

بعد توليد البيانات، ظهرت مشكلة عدم توازن عدد العينات بين الفئات المختلفة.

لذلك تم تطبيق أسلوب:

Oversampling

بحيث يتم زيادة عدد عينات الفئات الصغيرة حتى تصبح جميع النوايا متقاربة من حيث الحجم. أهداف هذه الخطوة:

- منع انحياز النموذج لفئة معينة .
- تحسين دقة التصنيف .
- رفع أداء النموذج للفئات قليلة العينات.

نظام فهم النية (Intent Classification)

تم إنشاء Intent Classifier لفهم نوع طلب المستخدم. النظام يدعم نوايا مثل:

- meal recommendation
- meal plan
- weekly plan
- meal analysis
- compare meals
- alternatives
- pre-workout
- post-workout

آلية التدريب

تم توليد بيانات تدريبية صناعية اعتماداً على البيانات الأصلية. ثم تم تدريب نموذج تصنيف باستخدام:


- Logistic Regression

مع:

- TF-IDF Features

لفهم نص المستخدم.

Intent Accuracy: 0.999213217938631



صورة 3 - confusion matrix

Semantic Matching

تم استخدام:

• SentenceTransformer

وبالتحديد:

• paraphrase-multilingual-MiniLM-L12-v2

لحساب التشابه الدلالي بين:

- سؤال المستخدم.
 - بيانات الوجبات.
- مما سمح بفهم المعنى وليس فقط الكلمات المطابقة.

Recommendation Engine

تم بناء محرك توصية هجين يعتمد على:

(1) التشابه النصي

باستخدام:

- cosine similarity
-

(2) مطابقة الهدف الغذائي

مثل:

- Weight Loss
 - Weight Gain
 - Maintenance
-

(3) مطابقة نوع الوجبة

مثل:

- Breakfast
 - Lunch
 - Dinner
 - Snack
-

(4) التقييم الغذائي

تم احتساب جودة الوجبة اعتماداً على:

- السعرات.
- البروتين.
- الدهون.

- الكربوهيدرات.

Nutrition Prediction Model

تم بناء نموذج لتوقع القيم الغذائية للوجبات.

النموذج يتنبأ بـ:

• Calories

• Protein

• Carbs

• Fat

باستخدام:

• MultiOutputRegressor

• Ridge Regression

هذا النموذج ميزة إضافية يمكن استخدامها في الإصدار الجديد في حال أردنا النموذج تخمين القيم الغذائية لوجبة.

Memory & Session State

تم إضافة مفهوم الذاكرة داخل المحادثة بحيث يستطيع النظام:

• تذكر الهدف الحالي.

• تذكر نوع الوجبة.

• متابعة الحوار.

• طلب توضيح عند الحاجة.

Greeting Detection

تم بناء نظام بسيط لاكتشاف التحية باستخدام:

• Regex

• Word Matching

لدعم:

• العربية.

• الإنجليزية.

مميزات النهج الحالي

مقارنة بالـ Deep Learning ، قدم النظام الحالي:

- دقة أعلى.
- تحكم كامل بالمخرجات.
- استقرار أكبر.
- توصيات منطقية.
- سرعة تنفيذ أعلى.
- استهلاك موارد أقل.
- سهولة التعديل والتطوير.
- تقليل Hallucination .

مقارنة بين النهجين

العنصر	Deep Learning	النظام الحالي
نوع النظام	Generative AI	Hybrid ML System
التحكم بالمخرجات	منخفض	مرتفع
سرعة التنفيذ	أبطأ	أسرع
GPU الحاجة إلى	مرتفعة	منخفضة
الهلوسة	مرتفعة	منخفضة
دقة التوصيات	غير مستقرة	أكثر استقراراً
سهولة التطوير	أصعب	أسهل
ضخمة Dataset الاعتماد على	نعم	أقل
قابلية التفسير	ضعيفة	أعلى

جدول 4 - مقارنة بين المظام الهجين و DL

الاستنتاج النهائي

أظهرت التجارب أن استخدام Deep Learning فقط لم يكن مناسباً لطبيعة النظام الغذائي بسبب:

- صعوبة التحكم بالمخرجات.
- ضعف الدقة الغذائية.
- ظهور معلومات غير موثوقة.

لذلك تم اعتماد نظام هجين يجمع بين:

- Machine Learning
- Semantic Search
- Recommendation Systems
- Rule-Based Logic

وهو ما أعطى نتائج أكثر استقراراً وموثوقية وملاءمة لمتطلبات المشروع النهائي.

تصميم واجهات المستخدم (User Interface Design)

تم تصميم واجهات المستخدم بهدف توفير تجربة استخدام سهلة وتفاعلية تسمح للمستخدم بالتواصل مع النظام بصورة طبيعية وسريعة، مع التركيز على تبسيط عملية الحصول على التوصيات الغذائية وتحليل الوجبات.

اعتمد النظام على مكتبة:

• Streamlit

◦ سهولة التطوير وسرعة التنفيذ

تسمح ببناء واجهات تفاعلية باستخدام لغة Python فقط دون الحاجة إلى تقنيات- Front-End معقدة مثل HTML أو CSS أو JavaScript.

◦ واجهة تفاعلية ديناميكية

تدعم تحديث النتائج بشكل مباشر عند إدخال المستخدم للبيانات دون الحاجة لإعادة تحميل الصفحة.

◦ دعم مكونات جاهزة (Widgets)

توفر عناصر متعددة مثل:

- حقول إدخال النصوص (Text Input)
- الأزرار (Buttons)
- القوائم المنسدلة (Dropdown Lists)
- مربعات الاختيار (Checkboxes)
- الجداول والرسوم البيانية

◦ إدارة حالة الجلسة (Session State)

- تتيح حفظ معلومات المستخدم أثناء المحادثة مثل:
- الهدف الغذائي الحالي

- نوع الوجبة
 - آخر توصيات النظام
 - بيانات الحوار السابقة
 - سهولة دمج نماذج الذكاء الصناعي
 - تسمح بتشغيل نماذج التعلم الآلي ومعالجة اللغة الطبيعية مباشرة داخل التطبيق.
 - إمكانية النشر السريع (Deployment)
 - يمكن نشر التطبيق بسهولة على:
 - Streamlit Cloud
 - Hugging Face Spaces
 - خوادم محلية أو سحابية
-

مكونات الواجهة الرئيسية


تتكون واجهة النظام من عدة عناصر رئيسية:

1) واجهة المحادثة (Chat Interface)

تمثل الواجهة الأساسية للتفاعل بين المستخدم والنظام، حيث يمكن للمستخدم:

- إدخال الأسئلة أو الطلبات الغذائية .
- طلب اقتراح وجبات .
- تحليل وجبات غذائية .
- مقارنة وجبات مختلفة .
- طلب خطط غذائية يومية أو أسبوعية .
- الحصول على بدائل غذائية .

تعرض الرسائل بأسلوب المحادثات الحديثة (Chat Style) لتقريب تجربة الاستخدام من المساعدات الذكية المعروفة.




صورة 4 – واجهة - 1

(2) أسئلة التوضيح (Clarification Questions)

في حال عدم توفر معلومات كافية لفهم المستخدم، يقوم النظام بعرض أسئلة توضيحية تفاعلية بهدف جمع المعلومات الناقصة مثل:

- الهدف الغذائي .
- نوع الوجبة .
- اسم الوجبة .



صورة 5 واجهة - 2

(3) عرض نتائج التوصية والتحليل

يتم عرض نتائج النظام بشكل منظم يتضمن:

- اسم الوجبة .
- السعرات الحرارية .
- كمية البروتين .
- كمية الكربوهيدرات .
- كمية الدهون .
- تفسير سبب الاقتراح .

مما يساعد المستخدم على اتخاذ قرارات غذائية أفضل.

Memory & History

Stored Memory

No memory stored

Clear Memory

Compare between Rice with Peas and Carrots with Chicken VS kabasa chicken

Meal Comparison

Best choice for Maintenance: Rice with Peas and Carrots with Chicken

Why? higher protein

Rice with Peas and Carrots with Chicken

Calories

610 kcal

Protein

36 g

Carbs

66 g

Fat

18 g

Semolina Porridge with Dates

Calories

420 kcal

Protein

14 g

Carbs

62 g

Fat

10 g

Nutrition Comparison

Metric	Rice with Peas and Carrots with Chicken	Semolina Porridge with Dates
Calories	610	420
Protein	36	14
Carbohydrates	66	62
Fat	18	10

AI Summary

Rice with Peas and Carrots with Chicken has higher protein.

Rice with Peas and Carrots with Chicken is higher in calories.

Semolina Porridge with Dates is lower in fat.

Ask me anything about nutrition...

صورة 6 واجهة - 3

43

الفصل الأخير: الأعمال المستقبلية

يمكن تطوير النظام لاحقاً بإضافة:

- حساب BMI و BMR تلقائياً
- ربط النظام بقواعد بيانات غذائية حقيقية
- دعم صور الطعام
- التعرف على الطعام من الصور
- توصيات رياضية
- دعم الأمراض المزمنة
- دمج Wearables
- Fine-tuning مستقبلي

(References)المراجع

[1]AI nutrition recommendation using a deep generative model and ChatGPT.

[2]ChatGPT as a Virtual Dietitian: Exploring Its Potential as a Tool for Improving Nutrition Knowledge.

[3]Towards interactive explanation based nutrition virtual coaching systems.

[4] Sentence Transformers Documentation:
[https://www.sbert.net/Transformers Documentation.](https://www.sbert.net/Transformers%20Documentation)

[5] Scikit-Learn Documentation:
<https://scikit-learn.org/>

[6] Hugging Face Documentation:
<https://huggingface.co/docs>